

Agente investigador sobre informes 10-K

Responde preguntas sobre los informes anuales de seis tecnológicas y cita de dónde sale cada dato.

El corpus y las cuatro herramientas

48

secciones: 6 empresas × FY2024 y
FY2025 × apartados 1A, 7, 7A y 8

650.000

tokens de texto, en 1.749
fragmentos

135

cifras oficiales en XBRL

herramienta	qué devuelve	coste
list_available	empresas y ejercicios disponibles	gratis
get_xbml_fact	una cifra oficial exacta	gratis y exacta
search_filings	los fragmentos más parecidos	barata, aproximada
read_section	una sección entera	cara: hasta 34.000 tokens

La tarea central es elegir bien entre ellas: una cifra se pide a XBRL, un matiz del texto se busca, y leer una sección entera es el último recurso.

Cómo enruta el agente



Comparativas: dos consultas exactas, una por ejercicio. Empresa fuera del corpus: comprueba con `list_available` y responde `fuentes = ninguna`.

Qué protege al agente

capa	qué hace	cuándo actúa
Guardarraíl XBRL	devuelve el desajuste al modelo; nunca corrige la cifra	cifra fuera de 0,5 % o 1 USD
Limitador	no ejecuta la herramienta y le pide responder con lo que tiene	más de 8 llamadas
Salida vacía	pide la respuesta estructurada en el mismo hilo	el modelo cierra sin respuesta
Reintento	repite la llamada al modelo hasta dos veces	error transitorio del proveedor
Modelo de reserva	pasa a gemini-3.5-flash-lite y no vuelve al primario	error 401, 402 o 429

5
preguntas en las que saltó el guardarraíl

4 de 5
acabaron bien tras la intervención

0
cifras inventadas en huecos (baseline: 1)

Cómo lo evaluamos

Golden set: 20 preguntas

8 numéricas, 3 de ellas huecos: el dato no está en el corpus y lo correcto es decirlo

6 comparativas entre FY2024 y FY2025

6 extractivas, ancladas a una frase literal del informe

Cita

existe literal en el fragmento que indica y está junto a la frase de referencia

Cifra

coincide con XBRL dentro de 0,5 % o 1 USD

Trayectoria

pasó por la herramienta que tocaba

Acierto = respuesta correcta y camino correcto. Con 20 preguntas, cada proporción lleva su intervalo de Wilson y la comparación entre sistemas, un contraste de McNemar exacto.

Retrieval: cada mejora, medida

configuración	recall@1	recall@5	MRR	latencia	coste
denso (punto de partida)	0,00	0,25	0,06	0,7 s	0
+ filtro de metadatos	0,25	0,67	0,44	0,2 s	0
+ BM25 (híbrido)	0,25	0,58	0,40	0,3 s	0
filtro + reescritura en inglés	0,67	0,75	0,71	4,9 s	0,19 ¢
filtro + BM25 + reescritura	0,58	0,92	0,74	4,9 s	0,19 ¢
+ reordenación con RRF (final)	0,67	0,92	0,78	5,2 s	0,19 ¢

12 preguntas con frase de referencia. Frente al punto de partida (McNemar): el filtro solo no es significativo ($p = 0,062$); desde la reescritura, sí ($p \leq 0,031$). La reescritura cuesta una llamada al modelo por búsqueda: 0,19 ¢ y unos 5 s.

Baseline contra sistema final

sistema	extractiva	numérica	comparativa	hueco	total	recall@5	coste	latencia	llamadas
baseline	83 %	75 %	0 %	33 %	55 %	25 %	1,23 ¢	17,7 s	3,4
final	83 %	100 %	83 %	100 %	90 %	92 %	1,65 ¢	22,3 s	2,6

Qué mejoró

Comparativas de 0 a 5 de 6. Huecos de 1 a 3 de 3. Numéricas de 6 a 8 de 8.

Qué costó

+0,42 ¢ y +4,6 s por pregunta. Casi todo es la reescritura de la consulta.

Misma base

Mismo modelo en los dos: gemini-3.8-flash. El baseline se congeló antes de mejorar nada.

CONTRASTE ESTADÍSTICO

11/20 → 18/20

McNemar exacto: $p = 0,016$

7 preguntas que el baseline fallaba y el final acierta; 0 al revés

IC 95 % de Wilson

baseline 34–74 % · final 70–97 %

¿Qué aporta el retrieval al agente?

sistema	aciertos	recall@5	coste	llamadas
baseline	11/20	25 %	1,23 ¢	3,4
final con el retrieval del baseline	17/20	25 %	1,81 ¢	2,8
final	18/20	92 %	1,65 ¢	2,6

El recall@5 del buscador pasa de 25 % a 92 %; el acierto del agente sube una pregunta.

El agente ya filtraba por empresa y ejercicio en sus propias llamadas a search_filings, y las cifras las saca de XBRL.

La mayor parte de la mejora viene del agente: prompt, guardarraíl y robustez. El retrieval aporta sobre todo menos llamadas.

Qué no funcionó y limitaciones

Probado sin mejora

BM25 junto al denso: recall@5 de 0,67 a 0,58.

Reordenar sin traducir la consulta: recall@5 de 0,67 a 0,58; el cross-encoder está entrenado en inglés.

Reordenar sin fusionar: mejor recall@1 (0,83), pero recall@5 de 0,83 frente a 0,92 con RRF.

Limitaciones

Tolerancia de 1 USD: demasiado laxa para valores por acción; 12 frente a 11,86 pasaba.

El modelo no es determinista: versiones anteriores del agente dieron entre 16 y 18 de 20; del final hay una sola corrida.

Los 2 fallos del final: cita correcta pero lejos de la frase de referencia.

Preguntas ciegas

```
evaluar("ciegas.jsonl")
```

	golden propio	ciegas	delta
aciertos	18/20 (90 %)	9/10 (90 %)	+0 pp
coste medio	1,65 ¢	1,70 ¢	+0,04 ¢
latencia media	22,3 s	35,8 s	+13,5 s

Extractivas 2/3, numéricas 3/3 (dos son huecos: ninguna cifra inventada), comparativas 4/4. Único fallo, ho-002: la cita es literal y correcta, pero sin el chunk_id del que sale.

El acierto no baja. Con 10 preguntas el IC 95 % va de 60 % a 98 %. La latencia sube en todas las familias, también en preguntas de una sola llamada.